

Terk Edilmiş Bagaj Algılama için Akıllı Güvenlik Sistemi

Intelligent Surveillance System for Abandoned Luggage

Damla Gül Altunay, Naciye Karademir, Okan Topçu

Bilgisayar Mühendisliği Bölümü

Orta Doğu Teknik Üniversitesi,

Kuzey Kıbrıs Kampüsü

Kalkanlı, Kuzey Kıbrıs

{altunay.damla, karademir.naciye, otopcu}@metu.edu.tr

Cem Direkoğlu

Elektrik – Elektronik Mühendisliği Bölümü

Orta Doğu Teknik Üniversitesi,

Kuzey Kıbrıs Kampüsü

Kalkanlı, Kuzey Kıbrıs

cemdir@metu.edu.tr

Özetçe— Bu bildiride, kamuya açık alanlarda terk edilmiş olan bagaj ve çanta gibi nesnelerin tespit edilmesi için bilgisayarlı görü algoritmalarına dayanan otomatik bir yöntem önerilmektedir. İlk olarak, arka plan çıkarma ve ön plan modelleme tekniğiyle, bir süre önceki görüntülerde görünmeyen ve sonradan statik durumuna geçen nesneler tespit edilmekte ve daha sonra tespit edilen statik nesnelerin bagaj olup olmadığı Daha Hızlı Bölge Tabanlı Konvolüsyonel Sinir Ağı (İng. Faster Region Proposal Convolutional Neural Network - Faster R - CNN) tekniği kullanılarak belirlenmektedir. Aynı zamanda, bagaja en yakın kişi belirlenip sahibi olarak tanımlanmaktadır. Bundan sonra olay analiz safhası başlamaktadır. Eğer tanımlanan kişi belli bir süre içerisinde (örneğin 30 saniye) bagaj bölgesinde değilse, bagaj sınırlayıcı bir kutuyla gösterilip "terk edilmiş" olarak adlandırılmaktadır. Değerlendirmeler, önerilen yaklaşımın etkili ve hızlı olduğunu göstermektedir.

Anahtar Kelimeler — Gözetleme sistemleri; video işleme; nesne algılama ve tanıma; olay tanıma.

Abstract— In this paper, an automatic method based on computer vision for the detection of abandoned luggage/bag in public spaces is proposed. First, with the background subtraction and foreground modeling technique, objects that were not present in the previous frames and have appeared later on as a static object are detected and then whether they are luggage or not are determined using the Faster Region Proposal Convolutional Neural Network (Faster R-CNN) technique. At the same time, the person closest to the luggage is identified and defined as the owner. After that, the event analysis phase is being started. If the identified person is not in the luggage area within a certain period of time (e.g. 30 seconds), the luggage is defined as "abandoned" with a bounding box. The assessments show that the proposed approach is effective and rapid.

Keywords — Surveillance systems; video processing, object detection and recognition; event recognition.


I. GİRİŞ

Havaalanı, otobüs terminalleri gibi insanların yoğun olduğu kamuya açık alanlarda güvenliğin sağlanması, denetlenmesi ve gerekli önlemlerin alınması günümüzde önemli bir problem olarak karşımıza çıkmaktadır. Problemin en önemli bileşimlerinden biri, ilgili alanın çeşitli şüpheli olaylara karşı (örneğin sahihsiz bagaj tespiti) sürekli (7/24) gözetim gerektirmesidir. Özellikle bu tip alanlar iyi bir şekilde gözetleme kameralarıyla donatılmış olsalar bile şüpheli olayların tespiti genelde güvenlik personeli tarafından yapılmaktadır. Diğer bir deyişle, çoğu güvenlik sistemi, tehlikeli durumların tespiti ve kontrolü için (yasadışı maddelerin kontrolü, haklarında

yakalama emri çıkarılan kişileri tespiti vb.) güvenlik personellerine ihtiyaç duymaktadır. Güvenlik personeli ne kadar eğitilmiş ve kabiliyetli olursa olsun ilgili alanların büyüklüğü, kameraların fazlalığı şüpheli olayların tespiti için bazen çok kısa zaman gerektirmesi gibi nedenlerden kendi başına bu tespitleri yapabilen akıllı video gözetim sistemlerine gereksinim duyulmaktadır. Bu kapsamda şüpheli (tehlikeli) nesnelerin tespiti, bu tür durumlarda ve sistemlerde güvenliği sağlamak için en önemli uygulamalardan biri olarak görülmektedir.

Bu nesneler, dinamik şüpheli davranışlar (diğerlerine saldırmaya çalışan bir kişi) ve statik tehlikeli nesneler (örneğin, kamuya açık yerlerde bırakılan bagaj veya bomba gibi) [1] olmak üzere iki ana sınıfa ayrılabilir. Bu bildirinin kapsamı ikinci kategoriye girip, terkedilmiş bagaj/çanta gibi nesnelerin tespit edilmesini amaçlamaktadır. Bu tür sistemlerle ilgili birçok araştırma sunulmuş olsa da kullanılan teknikler birbirinden farklı olup, çoğu yalnızca bilgisayarlı görü algoritmalarına dayanmaktadır. Her bir çözümün doğruluk ve hesaplama parametreleri üzerinde kendi avantajlarıyla beraber kısıtlamaları mevcuttur. Literatürde başlıca iki yöntem türü bulunmaktadır. Birinci yöntem [2]'de çalışmada sergilendiği gibi hareketli nesnelerin takibine dayanırken, diğer yöntem ise şüpheli bölgeyi tespit etmek için arka plan modelini kullanmaya yöneliktir [3]. Takibe dayalı yöntemler çözümü birçok durum için zor olan, nesnelerin bir araya gelmesi, bölünmesi, bırakılması, ve oklüzyonu gibi sorunlarla karşılaşmaktadır [4]. Ayrıca kalabalık ortamlarda tüm nesneleri izlemek yüksek hesaplama maliyetine sebep olmaktadır. Öte yandan, arka plan modelini çıkarmaya dayanan hareketli nesne tespiti, performans ve güvenilirlik açısından daha iyi bir uzlaşma sağlayabilmekte ve algoritmanın bir sonraki aşaması için uygun bir ortam yaratabilmektedir fakat algılama için bu yöntemi kullanmak yeterli değildir. Arka plan çıkarıldıktan sonra tespit edilen nesnelerin tanımlanması gerekir. İlgili olduğumuz nesne (bagaj ve çantalar) çeşitli boyutlarda, şekilde ve renkte olabileceğinden bilgisayarlı görü algoritmalarının getirdiği kısıtlamaya bir çözüm olarak algoritmamıza makine öğrenmesini dahil ettik. Böylece farklı özelliklere sahip olan bir iş çantasını ve müzik aletini aynı kategoride inceleyip bagaj olarak adlandırıyoruz.

Buna benzer bir çalışma [5], 2017 yılında yapılmış olup Konvolüsyonel Sinir Ağı (KSA) kullanılarak terk edilmiş objelerin bagaj olduğu belirlenmiştir. KSA'nın mimarisi araştırmaya özel olarak tasarlanmıştır, ancak bagaj tespitlerinin doğrulukları ve verdiği sonuçlar, [5]'de de belirtildiği üzere, tatmin edici olmamakla beraber terk edilmiş nesnenin sahibini bulmakla da ilgilenilmemiştir. Bir diğer çalışma olan [6]'de ise



Şekil 1. Örnek Program Çıktısı (ABODA-Video1)

terk edilmiş nesneler hiçbir sınıflandırma yapılmadan bilgisayarlı görü algoritmalarıyla tespit edilmiş ve nesnelerin sahipleri KSA kullanılarak bulunmuştur. Bu çalışmada esas amaçlanan, terk edilmiş bagaj tespiti değil, ilgili nesneye etraftan nasıl müdahale edildiğini tespit etmektir. Gerçekleşen müdahale "Sahibi tarafından alındı", "Sahibi olmayan biri tarafından alındı" ve "Hırsızlık" şeklinde belirlenip sınıflandırılmıştır.

Bu çalışmamızda temel amacımız diğer çalışmalardan farklı olarak terkedilmiş nesnenin bagaj olarak tespiti ve beraberinde sahibini bulmaktır. Önerilen yöntemimizde ilk olarak ikili ön plan modelleme yöntemini kullanarak önceki görüntülerde görünmeyen statik nesneleri tespit ediyoruz. Tespit edilen statik nesnelerin bagaj olup olmadığını Faster R-CNN tekniğini [7] kullanarak belirliyoruz. Aynı zamanda hem bagaj hem de kişi veri kümesiyle oluşturulmuş eğitilmiş modeli kullanarak bagaja en yakın kişiyi sahibi olarak tanımlıyoruz. Sahibinin, bagajın etrafında tanımlanan mesafe aralığı ile sınırlandırılmış bölgede bulunmaması durumunda zaman tutmaya başlanır. Önceden belirlenen bir süre (30 saniye) sonra kişi belirtilen bölge içerisinde değilse bagajı sınırlayıcı kutuyla gösterip "terk edilmiş bagaj" olarak adlandırıyoruz.

Önerilen yöntemde daha önceki sistemlerden farklı olarak yapılan yenilikler şu şekilde özetlenebilir: ikili ön plan modelleme yöntemiyle Faster R-CNN algoritmasını birleştirerek statikleşen bagajın ve terkeden kişinin bulunması, eğitilmek üzere yeni bir bagaj veri kümesinin ve farklı senaryolar içeren video veri kümesinin oluşturulması. Elde ettiğimiz test sonuçları, önerilen yaklaşımın etkili ve hızlı olduğunu göstermektedir.

II. ÖNERİLEN YÖNTEM

Bildirinin bu aşamasında önerilen yöntemin detayları ele alınmakta ve açıklanmaktadır. Önerilen yaklaşım temel olarak, girdi video sekansındaki statik nesnelerin belirlenmesi, sonrasında bu nesnelerin bagaj olup olmadığının kontrolü (Şekil 1-a) ardından, eğer bagaj ise yanındaki sahibini bulup (Şekil 1-b) aralarındaki ilişkiyi analiz etmeye (Şekil 1-c) dayanmaktadır. Algoritma aşağıdaki adımlardan oluşmaktadır.

- Arka plan çıkarma ve ikili ön plan modelleme,
- Bagaj tanıma ve sahibi ile ilişkilendirme,
- Olay analizi.

A. Arka plan çıkarma ve ikili ön plan modelleme

Sistem gerçek zamanlı video gözetiminde kullanılacağı için bilgisayarlı görü tekniklerinden yararlanılmıştır ve bu ana kısımlardan birini oluşturmaktadır. Video sekanslarını ön işleme olmadan sadece makine öğrenmesini kullanarak işlemek zaman alıcı hesaplamalara ve sistemimizde istemediğimiz gecikmelere neden olmaktadır. [6]'e göre, yöntemlerin ilk aşamasında bilgisayarlı görü teknikleri kullanmak sistemi daha hızlı kılıyor.

Hareketsizlik terk edilmiş bir nesnenin en bariz özelliğidir. Bu yüzden çalışmamızda arka plan çıkarma tekniği

kullanılmaktadır. Arka plan çıkarma, görüntülerden alınan bir dizi video sekanslarını inceleyen ve hareket eden nesneleri hareketsizlerden ayırmak için kullanılan bir tekniktir. Bu teknikte Gaussian karışımı (İng. MOG) kullanılmıştır. Alınan her görüntüde piksel değeri algoritma geçmiş değerine göre tutulmaktadır [8]. Herhangi bir zamanda (t) piksel değeri (x_0, y_0) geçmişi: $X_1, \dots, X_t = \{V(x_0, y_0, i): 1 \leq i \leq t\}$


Tutulan değer MOG kullanılıp, algoritma geçmiş değerine modellenmektedir:

$$P(X_t) = \sum_{i=1}^K \omega_{i,t} \eta(X_t | \mu_{i,t}, \Sigma_{i,t})$$

Bulduğumuz bu sonuç KYM (İng. RGB) değerine göre değerlendirilir. Gaussian ve belirlediğimiz eşik değerine (T) göre ise ön plan ya da arka plan olduğuna karar verilir. Piksel değerleri ön planda 1 (beyaz), arka planda 0 (siyah) yapılır.


$$B = \operatorname{argmin}(\sum_{i=1}^B \omega_{i,t} > T)$$

İkili ön plan modellemede ise arka plan çıkarma sonucu uzun-dönem ve kısa-dönem olarak tutulmakta ve kısa-dönem olan daha sık güncellenmektedir. Sonradan bulgularımızı karşılaştırıyoruz ve bu karşılaştırmadan elde ettiğimiz sonuçları hareketsizleşmiş objeler olarak tutuyoruz. Bu teknikte yapılan karşılaştırma Şekil 2'de ayrıntılı olarak gösterilmektedir.



Şekil 2. Uzun ve kısa vadeli ön plandaki varsayımlar [9]

Çalışmamızda arka plan çıkarması için Gaussian karışımında algoritma geçmişi değerini her ikisi için 1 olarak tuttuk. Piksel eşik değeri ise kısa-dönem için 120, uzun-dönem için 1000 olarak tutulmaktadır. Öğrenme oranı, uzun-dönem için 0.0001 ve kısa-dönem için 0.002'dir.



Şekil 3. (Sahne, kısa-dönem, uzun-dönem, fark, terkedilmiş obje teklifi)

Şekil 3'te yöntemimizin sonuçları verilmektedir. Sırasıyla kendi oluşturduğumuz veri kümesinden alınan bir videodan bir sahne (Şekil 3a), kısa-dönem ve uzun dönem arka plan çıkarma sonucu (Şekil 3b, 3c), iki sonuç arasındaki farkı (Şekil 3d) ve bu sahne için önerilen statikleşen nesneleri görebiliriz (Şekil 3e).

B. Bagaj Tanıma ve Sahibi ile İlişkilendirme

Önerilen yöntemin bu adımında, bir önceki adımda belirlenmiş olan statik obje listesi eğitilmiş model yardımı ile sınıflandırılarak aralarından bagaj olanlar seçilmektedir. Dolayısıyla algoritmanın ikinci kısmı olarak belirlenen bu bölüm makine öğrenmesi içermekte ve bunun için Faster R-CNN algoritması kullanılmaktadır. Oluşturulan insan ve bagaj veri kümeleri birleştirilerek eğitim ve test kümesi olarak ikiye ayrıldı.


Araştırmalarımızın başında derin öğrenme ile nesne tespiti algoritmaları arasında en yeni ve iyi sonuç veren iki tanesini Sadece Bir Defa Bakıyorsun (İng. You Only Look Once - YOLO) ve Faster R-CNN seçerek hem eğitim hem de test aşamasında karşılaştırmalar yapıldı. Bu karşılaştırma, algoritmaların saniye biriminden nesne tespit hızları (NTP), bulunan nesnelerin doğruluk yüzdelere (DY) ve yanlış alarmlara (YA) göre yapıldı. Test kümemizin bir parçası dikkate alınarak oluşturulan Tablo-1'de de görüldüğü üzere, resim üzerinde en hızlı nesne tespitini yapan algoritma YOLO iken, doğruluk yüzdeleri en fazla Faster R-CNN olarak gözlemlendi. Sürdürdüğümüz çalışmada yanlış alarmları azaltmak ve güvenilirliği korumak amacıyla tespitlerde doğruluk payı en yüksek olan ikinci algoritmayı (Faster R-CNN'i) seçtik.

Tablo 1. Faster R-CNN ve YOLO karşılaştırılması

Resimdeki Bagaj Sayısı	Faster R-CNN		YOLO	
	NTP	DY	NTP	DY
1 bagaj	1,14	%99	0,36	%68
1 bagaj	1,30	%99	0,38	%47
1 bagaj	1,17	%98	0,37	%61
1 bagaj	0,96	%99	0,32	%31+%56 (1 YA)
2 bagaj	1,12	%99 + %93	0,43	%79+%7+%1 (1 YA)
2 bagaj	1,35	%99 + %95	0,36	%36+%11
5 bagajdan fazla	0,96	%89 – %99	0,32	%42
Ort.	1,14	%97,43	0,36	%52

Bölge tabanlı ağ kullanmamızdaki bir diğer neden ise algoritmanın bagaj tanıma kısmına statikleştiği tespit edilen nesneyi göndermek yerine çevresindeki bölgeyi gönderme tercihimizden kaynaklanmaktadır. Objenin statikliği süresince alınan her sekansta onu çevreleyen sınırlayıcı kutunun çeşitli nedenlerden dolayı (gölgelenme, parlaklık, oklüzyon vb.) lokasyonu değişim gösterebilir. İlk sınırlayıcı kutunun oranları doğrultusunda belirlenen bölge içerisindeki aynı objeyi temsil eden diğer sınırlayıcı kutuları yoksayarak, Faster R-CNN ile nesne tanıma işlemini o obje için sadece bir kere gerçekleştirmekteyiz. Böylece gerçek zamanlı çalışabilen sistemimizde işlem süresini kısaltmaktayız.

Faster R-CNN, iki sınıftan oluşan eğitim kümesiyle beraber makine öğrenmesi uygulama iskeletlerinden biri olan Tensorflow kullanılarak eğitildi. Eğitim NVIDIA Quadro GPU üzerinde tamamlandı. Şekil 4'te eğitim sonucunda ortaya çıkan hata hesaplaması verilmiştir.



Şekil 4. Eğitim (kalın çizgiyle) ve Test (ince çizgiyle) adımlara oranla hata hesaplaması

Eğitilen model kullanılarak bagaj olduğu anlaşılan statik nesnelerin sahipleri, yine aynı model ile, en yakınındaki insanı tespit ederek bulunur. Sistemde tek kamera kullanıldığı baz alındığında ortamın kuşbakışı görüntüsünden elde edilen uzunluk bilgileri ile kamera açısının gördüğü alan oranlanıp bagaj ve çevresindeki insanlar arasındaki mesafe farkı hesaplanır. Bu çözüme ek olarak bagaj yanındaki insanların tespitinin hemen ardından ortalama bir insan boyu sisteme tanıtılır ve insan/lar için çizilen sınırlayıcı kutuyla bu uzunluk karşılaştırılarak pikselin santimetre cinsinden değeri hesaplanır. Böylece insan ve bagaj arasındaki piksel farklarından aralarındaki gerçek mesafe ölçüsü hesaplanabilir. Bagaj ve sahibi belirlendikten sonra ilişkilendirmek, bir sonraki kısım olan Olay Analizi için önemli olduğundan bulunan sınırlayıcı kutular numaralandırılarak sisteme kaydedilir.


C. Olay Analizi

Bagaj ve sahibi ilişkilendirildikten sonra sistem bu iki nesne arasındaki ilişkileri kontrol etmeye başlar. Kontroller iki parametre üzerinden gerçekleşir: zaman ve mesafe. Bagajın etrafında oluşturulan sınır PETS 2006 veri kümesindeki ölçümler[12] esas alınarak 3 metre olarak belirlenmiştir. Bagaj sahibi, eşyasından 3 metre uzlaştıktan sonra sistem uyarı durumuna geçer ve 30 saniye süreli geri sayım başlatılır. Bu süre zarfında, sahibi bagajının belirtilen 3 metre sınırları içerisinde gözükmez ise sistem alarm durumunu devreye sokar.

III. DEĞERLENDİRME

A. Bagaj ve Video Veri Kümesi Oluşturma

Önceden bazı veri kümeleriyle eğitilmiş olan bir modeli kendi sistemimize uygun hale getirmek için mimarisini değiştirmeden sadece insan ve bagaj üzerinde tekrar eğitim yeni bir model oluşturmamız gerekiyordu. Bu çalışmada, Tensorflow Nesne Tespiti Uygulama programlama ara yüzündeki Faster R-CNN ResNet mimarisi ile COCO veri kümesinde eğitilmiş model [10] kullanıldı. İnsan için gerekli olan veri kümesi INRIA İnsan veri kümesinden [11] yararlanılarak oluşturulurken, bagaj için kendi araştırmamızda kullanmak üzere 3000 resimden oluşan bir veri kümesi oluşturduk. Bu veri kümesindeki öğrenilen bagajların realiteye uygun olması adına arka planı tek renk olan resimlerden ziyade günlük hayatın içerisinde var olan senaryolardan oluşan resimler seçildi (Şekil 5).



Şekil 5. Bagaj veri kümesinden örnekler

Ayrıca sistemi test etmek amacıyla video veri kümeleri oluşturulmuş olup sonuçlar bir sonraki bölümde verilmiştir.

B. Sonuçlar ve Kıyaslama

Bildirinin bu bölümünde önerdiğimiz yöntemin verdiği sonuçlar, oluşturulan video veri kümesi ve ABODA [3] üzerinde test edilmiş ve Tablo-2’de sunulmuştur.

Tablo 2’de terkedilmiş bagaj tespiti araştırmalarında test amacıyla sıklıkla kullanılan [3] çalışması için oluşturulan ABODA veri kümesinin video sonuçları yer almaktadır. Videolardan sadece sistem amacına yönelik olarak kapalı ortamlarda olanları seçilmiş ve açıklamaları en sağdaki sütunda verilmiştir. Tabloda Gerçek Doğru (GD) (İng. Ground-Truth) videoda tespit edilmesi gereken terkedilmiş bagaj sayısını vurgularken, Doğru Sayısı (DS) (İng. True-Positive) program sonucunun verdiği doğru alarmları ve Yanlış Sayısı (YS) (İng. False-Positive) program sonucunun verdiği yanlış alarmları gösterir. Tablodaki verilerden hesaplanan kesinlik (İng. Precision) %83,33 ve hassasiyet (yakalama oranı) (İng. Recall) %100 olarak hesaplanmış ve veri kümesini oluşturan [3] çalışmaya göre daha başarılı sonuç elde edilmiştir.

Tablo 2. ABODA veri kümesi sonuçları

Video Numarası	GD	DS	YS	Senaryo Açıklaması
Video1	1	1	0	Kalabalık koridor
Video7	1	1	0	Işığın değişken olduğu kapalı ortam
Video8	1	1	1	Işığın değişken olduğu kapalı ortam
Video9	1	1	0	Kapalı Ortam
Video10	1	1	0	Kapalı Ortam

Programı test etmek için oluşturduğumuz video veri kümesi sonuçları Tablo 3’te verilmiştir. Bir önceki tablodan farklı olarak bu tabloda Yanlışlıkla Yapılamamışların Sayısı (YYs) (İng. False-Negative) sütunu eklenmiştir. Bu sütunda videoda tespit edilmesi gerekirken, sonuçlarda sergilenemeyen terkedilmiş bagajların sayısı verilmiştir. Video veri kümesinden çıkarılan kesinlik ve hassasiyet %87,5 olarak hesaplanmıştır.

Tablo 3. Yeni Oluşturulan Video Veri Kümesi Sonuçları

Video Numarası	GD	DS	YS	YYs	Senaryo Açıklaması
Video1	1	1	0	0	Laboratuvar ortamı
Video2	2	2	1	0	Kalabalık laboratuvar ortamı
Video3	1	1	0	0	Kapalı Ortam
Video4	2	2	0	0	Kalabalık kapalı Ortam
Video5	2	1	0	1	Işığın değişken olduğu sınıf ortamı

IV. VARGİ

Bu bildiride, kapalı ortamlarda terkedilmiş bagajların tespiti için uygulanan bilgisayarlı görü ve makine öğrenmesi algoritmalarıyla oluşturulmuş yaklaşım sunulmuştur. Önerilen algoritmada ilk olarak, arka plan modelleme kullanılarak statikleşen nesneler listelenmiş, listelenen nesnelerin bagaj olup olmadığı Faster R-CNN derin öğrenme nesne tespiti algoritmasıyla belirlenmiş ve son olarak da bu bagajların sahipleri bulunup aralarındaki olay analizleri incelenmiştir. Deneysel çalışmalar için ABODA ve bizlerin araştırma için oluşturduğu veri kümesi kullanılmıştır. Yapılan deneylerde önerilen yöntemin ilgili ortam ve sistemler için uygun ve daha önceki yapılan çalışmalara göre performansı yükseltici sonuçlar elde ettiği gözlemlenmiştir. Çalışmamızın bir sonraki adımı olarak olay analizi bölümünde kullanılmak üzere kişiyi yeniden tanımlama (İng. person re-identification) algoritmalarıyla bagaj sahibi tespitini geçmiş sahneleri inceleyerek bulmayı hedefliyoruz.

KAYNAKLAR

- [1] H. Kong, J.-Y. Audibert, and J. Ponce, “Detecting Abandoned Objects With a Moving Camera,” *IEEE Transactions on Image Processing*, vol. 19, no. 8, pp. 2201–2210, 2010.
- [2] M. Valera, S.A. Velastin, “Intelligent distributed surveillance systems: a review”, *IEE Proceedings - Vision, Image and Signal Processing*, 152(2), pp. 192-204, 2005.
- [3] K. Lin, S.-C. Chen, C.-S. Chen, D.-T. Lin, and Y.-P. Hung, “Abandoned Object Detection via Temporal Consistency Modeling and Back-Tracing Verification for Visual Surveillance,” *IEEE Transactions on Information Forensics and Security*, vol. 10, no. 7, pp. 1359–1370, 2015.
- [4] T. T. Zin, P. Tin, T. Tori and H. Hama, “A Probability-based Model for Detecting Abandoned Objects in Video Surveillance Systems,” *in Proceedings of the World Congress on Engineering*, London, U.K, 2012.
- [5] S. V. Sidiyakın and B. V. Vishnyakov, “Real-time detection of abandoned bags using CNN,” *Automated Visual Inspection and Machine Vision II*, 2017.
- [6] W. Liao, C. Yang, M. Y. Yang, and B. Rosenhahn, “Security Event Recognition for Visual Surveillance,” *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. IV-1/W1, pp. 19–26, 2017.
- [7] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017.
- [8] C. Stauffer and W. Grimson, “Adaptive background mixture models for real-time tracking,” *Proceedings. 1999 IEEE Computer Society Conference on Computer Vision and Pattern Recognition* (Cat. No. PR00149), vol. 2, pp. 246–252, 1999.
- [9] F. Porikli, Y. Ivanov, and T. Haga, “Robust Abandoned Object Detection Using Dual Foregrounds,” *EURASIP Journal on Advances in Signal Processing*, vol. 2008, no. 1, 2007.
- [10] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common Objects in Context,” *Computer Vision – ECCV 2014 Lecture Notes in Computer Science*, pp. 740–755, 2014.
- [11] Navneet DALAL. (2006). *INRIA Person Dataset* [Data file and code book]. Available from from Web site: <http://pascal.inrialpes.fr/data/>
- [12] L. Li, R. Luo, R. Ma, W. Huang, and K. Leman, “Evaluation of an IVS System for abandoned object detection on pets 2006 datasets,” *in Proc. IEEE Workshop on PETS*, 2006, pp. 91 – 98.